

6장. 질적 예측변수

Samprit Chatterjee and Ali S. Hadi - Chapter 6

Introduction

- 질적(qualitative), 범주형(categorical) 변수
 - ▶ 예: 성별, 결혼여부, 정당, 지역, 직업, 거주형태
 - ▶ 지시변수(indicator variable: 가변수, dummy variable)로 처리
- 가변수를 이용한 회귀모형의 예 (지역구분: 대도시, 중소도시, 농어촌)
 - ▶ 소득수준 = $\beta_0 + \beta_1 \times \text{지역구분}$ (make sense ?)
 - ▶ 소득수준 = $\beta_0 + \beta_{11} \times I(\text{대도시}) + \beta_{12} \times I(\text{중소도시})$
 - 대도시: 소득수준 = $\beta_0 + \beta_{11}$
 - 중소도시: 소득수준 = $\beta_0 + \beta_{12}$
 - 농어촌: 소득수준 = β_0
- 기저범주(base category), 대조그룹(control group)

급료조사 데이터

행	S	X	E	M	행	S	X	E	M
1	13876	1	1	1	24	22884	6	2	1
2	11608	1	3	0	25	16978	7	1	1
3	18701	1	3	1	26	14803	8	2	0
4	11283	1	2	0	27	17404	8	1	1
5	11767	1	3	0	28	22184	8	3	1
6	20872	2	2	1	29	13548	8	1	0
7	11772	2	2	0	30	14467	10	1	0
8	10535	2	1	0	31	15942	10	2	0
9	12195	2	3	0	32	23174	10	3	1
10	12313	3	2	0	33	23780	10	2	1
11	14975	3	1	1	34	25410	11	2	1
12	21371	3	2	1	35	14861	11	1	0
13	19800	3	3	1	36	16882	12	2	0
14	11417	4	1	0	37	24170	12	3	1
15	20263	4	3	1	38	15990	13	1	0
16	13231	4	3	0	39	26330	13	2	1
17	12884	4	2	0	40	17949	14	2	0
18	13245	5	2	0	41	25685	15	3	1
19	13677	5	3	0	42	27837	16	2	1
20	15965	5	1	1	43	18838	16	2	0
21	12336	6	1	0	44	17483	16	1	0
22	21352	6	3	1	45	19207	17	2	0
23	13839	6	2	0	46	19346	20	1	0

S: 급료 X: 경력연수 M: 관리(2 범주) E: 교육수준(3 범주)

회귀모형: 급료조사 데이터

$$S = \beta_0 + \beta_1 X + \gamma_1 E_1 + \gamma_2 E_2 + \delta_1 M_1 + \epsilon$$

$$E_{i1} = \begin{cases} 1, & \text{고교졸업,} \\ 0, & \text{그외.} \end{cases} \quad E_{i2} = \begin{cases} 1, & \text{대학졸업,} \\ 0, & \text{그외.} \end{cases}$$

$$M_i = \begin{cases} 1, & \text{관리책임 있음,} \\ 0, & \text{관리책임 없음.} \end{cases}$$

급료조사 데이터의 5개 obs

	S	X	E	M	E1	E2
1	13876	1	1	1	1	0
2	11608	1	3	0	0	0
3	18701	1	3	1	0	0
4	11283	1	2	0	0	1
5	11767	1	3	0	0	0

회귀모형: 급료조사 데이터

$$S = \beta_0 + \beta_1 X + \gamma_1 E_1 + \gamma_2 E_2 + \delta_1 M_1 + \epsilon$$

범주	E	M	회귀방정식
1	1	0	$S = (\beta_0 + \gamma_1) + \beta_1 X + \epsilon$
2	1	1	$S = (\beta_0 + \gamma_1 + \delta_1) + \beta_1 X + \epsilon$
3	2	0	$S = (\beta_0 + \gamma_2) + \beta_1 X + \epsilon$
4	2	1	$S = (\beta_0 + \gamma_2 + \delta_1) + \beta_1 X + \epsilon$
5	3	0	$S = \beta_0 + \beta_1 X + \epsilon$
6	3	1	$S = (\beta_0 + \delta_1) + \beta_1 X + \epsilon$

금료조사 데이터


회귀분석 결과

$$\hat{S} = 11,031 + 546X - 2,996E_1 + 147E_2 + 6,883M$$

변수	계수	표준오차	t-검정	p-값
상수	11.031.800	383.2	28.80	<0.0001
X	546.184	30.5	17.90	<0.0001
E_1	-2996.210	411.8	-7.28	<0.0001
E_2	147.825	387.7	0.38	0.7049
M	6883.530	313.9	21.90	<0.0001
$n = 46$	$R^2 = 0.957$	$R_a^2 = 0.953$	$\hat{\sigma} = 1027$	$d.f. = 41$


급료조사 데이터

X vs Standardized Residual




급료조사 데이터

Fitted value vs Residual



급료조사 데이터

Categories vs Standardized Residual




상호작용 변수

$$S = \beta_0 + \beta_1 X + \gamma_1 E_1 + \gamma_2 E_2 + \delta_1 M_1 \\ + \alpha_1 (E_1 \cdot M) + \alpha_2 (E_2 \cdot M) + \epsilon$$

상호작용 변수 : $E_1 \cdot M$, $E_2 \cdot M$

상호작용 변수를 포함한 모형

변수	계수	표준오차	t-검정	p-값
상수	11203.40	79.07	141.7	<0.0001
X	496.99	5.57	89.3	<0.0001
E_1	-1730.75	105.30	-16.4	<0.0001
E_2	-349.08	97.57	-3.6	0.0009
M	7047.41	102.60	68.7	<0.0001
$E_1 \cdot M$	-3066.04	149.30	-20.5	<0.0001
$E_2 \cdot M$	1836.49	131.20	14.0	<0.0001
$n = 46$	$R^2 = 0.999$	$R_a^2 = 0.999$	$\hat{\sigma} = 173.8$	$df = 39$





상호작용 변수를 포함한 모형

관측개체 33 제외

변수	계수	표준오차	t -검정	p -값
상수	11199.70	30.54	367.0	<0.0001
X	498.41	2.15	232.0	<0.0001
E_1	-1741.28	40.69	-42.8	<0.0001
E_2	-357.00	37.69	-9.5	<0.0001
M	7040.49	39.63	178.0	<0.0001
$E_1 \cdot M$	-3051.72	57.68	-52.9	<0.0001
$E_2 \cdot M$	1997.62	51.79	38.6	<0.0001
$n = 45$	$R^2 = 1.0$	$R_a^2 = 1.0$	$\hat{\sigma} = 67.13$	$d.f. = 38$

상호작용 변수를 포함한 모형

관측개체 33 제외



상호작용 변수를 포함한 모형

범주별 기본 급료의 추정

범주	E	M	계수	기본급료의 추정치 ^a	s.e. ^a	95% 신뢰구간
1	1	0	$\beta_0 + \gamma_1$	9459	31	(9398, 9520)
2	1	1	$\beta_0 + \gamma_1 + \delta + \alpha_1$	13448	32	(13385, 13511)
3	2	0	$\beta_0 + \gamma_2$	10843	26	(10792, 10894)
4	2	1	$\beta_0 + \gamma_2 + \delta + \alpha_2$	19880	33	(19815, 19945)
5	3	0	β_0	11200	31	(11139, 11261)
6	3	1	$\beta_0 + \delta$	18240	29	(18183, 18297)


회귀방정식의 체계: 두 집단 비교

ANalysis of COVAriance(ANCOVA)

- 1 각 집단이 분리된 회귀모형을 가지는 경우
- 2 모형들이 동일한 절편항을 가지지만 기울기가 다른 경우
- 3 모형들이 동일한 기울기를 가지지만 절편항은 다른 경우

회귀방정식의 체계: 두 집단 비교

다른 기울기와 다른 절편항을 가지는 모형



For $j = 1, 2$, $i = 1, 2, \dots, n_j$,

모형 1 (통합모형) $y_{ij} = \beta_0 + \beta_1 x_{ij} + \epsilon_{ij}$,

모형 2 (소수민족) $y_{i1} = \beta_{01} + \beta_{11} x_{i1} + \epsilon_{i1}$,

모형 2 (백인) $y_{i2} = \beta_{02} + \beta_{12} x_{i2} + \epsilon_{i2}$

고용전 검사(Pre-Employment Testing) 데이터

번호	TEST	RACE	JPERF	번호	TEST	RACE	JPERF
1	0.28	1	1.83	11	2.36	0	3.25
2	0.97	1	4.59	12	2.11	0	5.30
3	1.25	1	2.97	13	0.45	0	1.39
4	2.46	1	8.14	14	1.76	0	4.69
5	2.51	1	8.00	15	2.09	0	6.56
6	1.17	1	3.30	16	1.50	0	3.00
7	1.78	1	7.53	17	1.25	0	5.85
8	1.21	1	2.03	18	0.72	0	1.90
9	1.63	1	5.00	19	0.42	0	3.85
10	1.98	1	8.04	20	1.53	0	2.95

모형 1: $y_{ij} = \beta_0 + \beta_1 x_{ij} + \epsilon_{ij},$

모형 3: $y_{ij} = \beta_0 + \beta_1 x_{ij} + \gamma z_{ij} + \delta (z_{ij} x_{ij}) + \epsilon_{ij}$

$$z_{ij} = \begin{cases} 1, & \text{소수민족,} \\ 0, & \text{백인.} \end{cases}$$

고용전 검사(Pre-Employment Testing) 데이터

$$\text{모형 3: } y_{ij} = \beta_0 + \beta_1 x_{ij} + \gamma z_{ij} + \delta (z_{ij} x_{ij}) + \epsilon_{ij}$$

- 소수민족

$$\begin{aligned} y_{i1} &= \beta_0 + \beta_1 x_{i1} + \gamma + \delta x_{i1} + \epsilon_{i1} \\ &= (\beta_0 + \gamma) + (\beta_1 + \delta) x_{i1} + \epsilon_{i1} \end{aligned}$$

- 백인

$$y_{i2} = \beta_0 + \beta_1 x_{i2} + \epsilon_{i2}$$

모형 1 vs 모형 3(모형 2)

$$H_0 : \gamma = \delta = 0$$

표 6.7 고용 전 검사 데이터 대한 회귀분석 결과: 모형 1

변수	계수	표준오차	t-검정	p-값
상수	1.03	0.87	1.19	0.2486
TEST(X)	2.36	0.54	4.39	0.0004
$n = 20$	$R^2 = 0.52$	$R_a^2 = 0.49$	$\hat{\sigma} = 1.59$	df = 18

표 6.8 고용 전 검사 데이터 대한 회귀분석 결과: 모형 3

변수	계수	표준오차	t-검정	p-값
상수	2.01	1.05	1.19	0.0736
TEST(X)	1.31	0.67	1.96	0.0677
RACE(Z)	-1.91	1.54	-1.24	0.2321
RACE · TEST($X \cdot Z$)	2.00	0.95	2.09	0.0527
$n = 20$	$R^2 = 0.664$	$R_a^2 = 0.601$	$\hat{\sigma} = 1.41$	df = 16

모형 1 vs 모형 3(모형 2)

$$H_0 : \gamma = \delta = 0$$

$$F = \frac{[SSE(RM) - SSE(FM)]/2}{SSE(FM)/16} = \frac{[45.568 - 31.655]/2}{31.655/16} = 3.52$$

- 소수민족

$$Y_1 = 0.10 + 3.31X_1$$

- 백인

$$Y_2 = 2.01 + 1.32X_2$$

잔차플롯




그림 6.7 표준화잔차 대 검사점수: 모형 1




그림 6.8 표준화잔차 대 검사점수: 모형 3




그림 6.9 표준화잔차 대 인종: 모형 1

집단별 회귀분석

표 6.9 분리된 회귀분석 결과

표본	β_0	β_1	t_1	$p\text{-값}$	R^2	$\hat{\sigma}$	n
소수민족	0,10	3,31	5,31	0,001	0,78	1,29	8
백인	2,01	1,31	1,82	0,106	0,29	1,51	8




그림 6.10 표준화잔차 대 검사점수: 소수민족




그림 6.11 표준화잔차 대 검사점수: 백인

적절한 합격점수의 결정

소수민족의 경우

Y_0 : 적절한 업무수행에 필요한 최소점수,

X_0 : 그에 대응되는 고용전 검사의 최소점수

$$Y_0 = \hat{\beta}_0 + \hat{\beta}_1 X_0 \implies X_0 = \frac{Y_0 - \hat{\beta}_0}{\hat{\beta}_1}$$

X_0 에 대한 근사(approximate) 신뢰구간

$$X_0 \pm t_{(n-2, \alpha/2)} \frac{\hat{\sigma}/n}{\hat{\beta}_1}$$

적절한 합격점수의 결정

소수민족의 경우

With $Y_0 = 4$

$$X_0 = \frac{4 - 0.10}{3.31} = 1.18, \quad \hat{\sigma} = 1.29, \quad n = 10, \quad t_{(8,0.025)} = 2.31$$

고용전 검사점수의 합격점에 대한 95% 신뢰구간 : (1.09, 1.27)

동일한 기울기와 다른 절편항을 가지는 모형

모형 1 (통합모형) $y_{ij} = \beta_0 + \beta_1 x_{ij} + \epsilon_{ij}, j = 1, 2, i = 1, 2 \dots, n_j,$

모형 2 (소수민족) $y_{i1} = \beta_{01} + \beta_1 x_{i1} + \epsilon_{i1},$

모형 2 (백 인) $y_{i2} = \beta_{02} + \beta_1 x_{i2} + \epsilon_{i2}$

모형 3 $y_{ij} = \beta_0 + \beta_1 x_{ij} + \gamma z_{ij} + \epsilon_{ij}$

소수민족: $y_{i1} = \beta_0 + \beta_1 x_{i1} + \gamma + \epsilon_{i1} = (\beta_0 + \gamma) + \beta_1 x_{i1} + \epsilon_{i1}$

백 인: $y_{i2} = \beta_0 + \beta_1 x_{i2} + \epsilon_{i2}$

가설 검정: H_0 : 모형 1 vs H_1 : 모형 3

$$\begin{aligned} F &= \frac{[SSE(Model\ 1) - SSE(Model\ 3)]/1}{SSE(Model\ 3)/17} \\ &= \frac{45.568 - 40.322}{40.322/17} \\ &= 2.212 \\ &< F_{0.05}(1, 17) = 4.451 \end{aligned}$$

모형 1 vs 모형 3

```
> P140.fit3 = lm(JPERF~TEST+RACE,data=P140)
> summary(P140.fit3)
```

Call:
lm(formula = JPERF ~ TEST + RACE, data = P140)

Residuals:

	Min	1Q	Median	3Q	Max
	-2.7872	-1.0370	-0.2095	0.9198	2.3645

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.6120	0.8870	0.690	0.499578
TEST	2.2988	0.5225	4.400	0.000391 ***
RACE	1.0276	0.6909	1.487	0.155246

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.54 on 17 degrees of freedom
Multiple R-squared: 0.5724, Adjusted R-squared: 0.5221
F-statistic: 11.38 on 2 and 17 DF, p-value: 0.0007312

```
> anova(P140.fit1,P140.fit3)
```

Analysis of Variance Table

Model 1: JPERF ~ TEST
Model 2: JPERF ~ TEST + RACE

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	18	45.568				
2	17	40.322	1	5.2468	2.2121	0.1552

동일한 절편항와 다른 기울기를 가지는 모형

모형 1 (통합모형) $y_{ij} = \beta_0 + \beta_1 x_{ij} + \epsilon_{ij}, j = 1, 2, i = 1, 2, \dots, n_j,$

모형 2 (소수민족) $y_{i1} = \beta_0 + \beta_{11} x_{i1} + \epsilon_{i1},$

모형 2 (백 인) $y_{i2} = \beta_0 + \beta_{12} x_{i2} + \epsilon_{i2}$

모형 3 $y_{ij} = \beta_0 + \beta_1 x_{ij} + \delta (z_{ij} \cdot x_{ij}) + \epsilon_{ij}$

소수민족: $y_{i1} = \beta_0 + \beta_1 x_{i1} + \delta x_{i1} + \epsilon_{i1} = \beta_0 + (\beta_1 + \delta) x_{i1} + \epsilon_{i1}$

백 인: $y_{i2} = \beta_0 + \beta_1 x_{i2} + \epsilon_{i2}$

가설 검정: H_0 : 모형 1 vs H_1 : 모형 3

$$\begin{aligned} F &= \frac{[SSE(Model\ 1) - SSE(Model\ 3)]/1}{SSE(Model\ 3)/17} \\ &= \frac{45.568 - 34.708}{34.0708/17} \\ &= 5.3196 \\ &> F_{0.05}(1, 17) = 4.451 \end{aligned}$$

모형 1 vs 모형 3

```
> # p26: different slope & same intercept
> P140.fit4 = lm(JPERF~TEST+RaceTest,data=P140)
> summary(P140.fit4)

Call:
lm(formula = JPERF ~ TEST + RaceTest, data = P140)

Residuals:
    Min       1Q   Median       3Q      Max
-2.41100 -0.88871 -0.03359  0.97720  2.44440

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   1.1211     0.7804   1.437  0.16900
TEST          1.8276     0.5356   3.412  0.00332 **
RaceTest      0.9161     0.3972   2.306  0.03395 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.429 on 17 degrees of freedom
Multiple R-squared:  0.6319,    Adjusted R-squared:  0.5886
F-statistic: 14.59 on 2 and 17 DF,  p-value: 0.0002045

>
> anova(P140.fit1,P140.fit4)
Analysis of Variance Table

Model 1: JPERF ~ TEST
Model 2: JPERF ~ TEST + RaceTest
  Res.Df  RSS Df Sum of Sq  F    Pr(>F)
1     18 45.568
2     17 34.708   1    10.861 5.3196 0.03395 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

지시변수에 대한 다른 응용들

분산분석(ANOVA: analysis of variance)

처리 1	처리 2	처리 3	...	처리 k
y_{11}	y_{21}	y_{31}	$\cdots$	y_{k1}
y_{12}	y_{22}	y_{32}	$\cdots$	y_{k2}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
y_{1n_1}	y_{2n_2}	y_{3n_3}	$\cdots$	y_{kn_k}

$$y_{ij} = \mu_i + \epsilon_{ij} = \mu_0 + (\mu_i - \mu_0) + \epsilon_{ij} = \mu_0 + \alpha_i + \epsilon_{ij}$$

$$\text{FM: } y_{ij} = \mu_0 + \mu_1 x_{i1} + \cdots + \mu_p x_{ip} + \epsilon_{ij}, \quad p = k - 1$$

$$\text{RM: } y_{ij} = \mu_0 + \epsilon_{ij}$$

계절성

스키 판매액 데이터

번호	분기/년도	Sales	PDI	번호	분기/년도	Sales	PDI
1	Q1/64	37.0	109	21	Q1/69	44.9	153
2	Q2/64	33.5	115	22	Q2/69	41.6	156
3	Q3/64	30.8	113	23	Q3/69	44.0	160
4	Q4/64	37.9	116	24	Q4/69	48.1	163
5	Q1/65	37.4	118	25	Q1/70	49.7	166
6	Q2/65	31.6	120	26	Q2/70	43.9	171
7	Q3/65	34.0	122	27	Q3/70	41.6	174

$$\text{기본모형 : } S_t = \beta_0 + \beta_1 \cdot PDI_t + \epsilon_t$$

S_t : t 시점의 스키 매출액 , PDI_t : t 시점의 개인 가처분 소득

계절성

스키 판매액 데이터

- 가변수를 활용하여 계절성을 고려한 모형

$$z_{t1} = \begin{cases} 1, & t \text{ 번째 기간이 } 1/4\text{분기인 경우} \\ 0, & \text{그 외의 경우} \end{cases}$$

$$z_{t2} = \begin{cases} 1, & t \text{ 번째 기간이 } 2/4\text{분기인 경우} \\ 0, & \text{그 외의 경우} \end{cases}$$

$$z_{t3} = \begin{cases} 1, & t \text{ 번째 기간이 } 3/4\text{분기인 경우} \\ 0, & \text{그 외의 경우} \end{cases}$$

계절성

스키 판매액 데이터

Call:

```
lm(formula = Sales ~ PDI + factor(Q), data = P149)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-2.51356	-0.86028	0.03654	0.67965	2.67306

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	15.12513	1.00894	14.991	< 2e-16 ***
PDI	0.19904	0.00619	32.155	< 2e-16 ***
factor(Q)2	-5.63694	0.51996	-10.841	9.83e-13 ***
factor(Q)3	-5.64522	0.52051	-10.846	9.72e-13 ***
factor(Q)4	-0.35312	0.52150	-0.677	0.503

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 1.162 on 35 degrees of freedom

Multiple R-squared: 0.9728, Adjusted R-squared: 0.9697

F-statistic: 313 on 4 and 35 DF, p-value: < 2.2e-16

계절성

스키 판매액 데이터



회귀모수의 시간에 걸친 안정성

Y : 공공교육에 사용되는 개인의 교육비 지출

X_1 : 개인소득

X_2 : 1,000명당 18세 미만의 인구수

X_3 : 1,000명당 도심거주 인구수

$$T_{i1} = \begin{cases} 1, & i \text{ 번째 관측값이 1965년에 해당하는 경우,} \\ 0, & \text{그외의 경우} \end{cases}$$

$$T_{i2} = \begin{cases} 1, & i \text{ 번째 관측값이 1970년에 해당하는 경우,} \\ 0, & \text{그외의 경우} \end{cases}$$

회귀모수의 시간에 걸친 안정성

$$\begin{aligned} Y = & \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 \\ & + \gamma_1 T_1 + \gamma_2 T_2 \\ & + \delta_1 T_1 \cdot X_1 + \delta_2 T_1 \cdot X_2 + \delta_3 T_1 \cdot X_3 \\ & + \alpha_1 T_2 \cdot X_1 + \alpha_2 T_2 \cdot X_2 + \alpha_3 T_2 \cdot X_3 \\ & + \epsilon \end{aligned}$$

회귀모수의 시간에 걸친 안정성

- For 1960

$$Y = (\beta_0 + \gamma_1) + (\beta_1 + \delta_1)X_1 + (\beta_2 + \delta_2)X_2 + (\beta_3 + \delta_3)X_3 + \epsilon$$

- For 1970

$$Y = (\beta_0 + \gamma_2) + (\beta_1 + \alpha_1)X_1 + (\beta_2 + \alpha_2)X_2 + (\beta_3 + \alpha_3)X_3 + \epsilon$$

- For 1975

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$$

$$H_0 : \gamma_1 = \gamma_2 = \delta_1 = \delta_2 = \delta_3 = \alpha_1 = \alpha_2 = \alpha_3 = 0$$